

Checklist EC2

Chạy real-data experiment — Aegis-Agency

Phiên bản tiếng Việt: đi từng bước từ trái qua phải

0. Trạng thái hiện tại (đã biết)

- Benchmarks đã có ở máy Windows: `D:\textbackslash Data\textbackslash benchmarks` (7 thư mục: *advbench*, *benign*, *dan*, *formal*, *harmbench*, *injecagent*, *second_order*)
- Pilot local đã chạy bằng Ollama (llama3.2:3b) — chưa đủ cho paper, không dùng làm kết quả
- SSH key `$\sim \$/.ssh/aegis.pem` — **chưa có** (chỉ có `known\_hosts`)

1. Chuẩn bị trước khi thuê (máy Windows)

- Tạo key pair trên AWS Console → tải `aegis.pem` → đặt vào `$\sim \$/.ssh/aegis.pem`
- (Windows) Phân quyền cho key: `icaccls "aegis.pem" /inheritance:r /grant:r "$env:USERNAME:R"`
- Chuẩn bị HF_TOKEN (Hugging Face read token) nếu dùng `meta-llama/Llama-3.1-8B-Instruct` (repo gated)

2. Thuê instance EC2

- Instance: `g5.xlarge` (1×A10G 24 GB VRAM, 4 vCPU, 16 GB RAM) — đủ cho full run Table 5/6
 - Tiết kiệm: `g4dn.xlarge` (T4 16 GB VRAM) — vừa đủ 1 model 8B, ít dư địa
 - Muốn RQ4 đa backbone ngay: `g5.12xlarge` (4×A10G 96 GB VRAM)
- AMI: Ubuntu 22.04/24.04 (driver NVIDIA + CUDA 12.x sẵn)
- Disk: root $\geq$ **50 GB** (weights + vLLM cache + benchmarks)
- Security group: mở **SSH inbound (TCP 22)** từ IP của bạn. Các port vLLM (8001+) chỉ bound localhost nên không cần mở public

3. Provision server (một lần)

- SSH vào: `ssh -i $\sim \$/.ssh/aegis.pem ubuntu@\textless ec2-host\textgreater`
- Clone repo: `git clone <repo-url>` rồi `cd AegisAgency`
- Chạy: `bash scripts/ec2/setup.sh` (cài python3.11, .venv, pip install -e ".[ec2]", tạo /data/benchmarks, chạy sanity test ~67 tests)

4. Upload benchmarks (một lần, từ máy Windows)

- Chạy từ thư mục repo:

```
powershell -ExecutionPolicy Bypass -File scripts/ec2/upload_data.ps1 -HostTarget ubuntu@<ec2-host> -Key "$env:USERPROFILE\.ssh\aegis.pem"
```
- Verify trên server: 7 thư mục nằm tại `/data/benchmarks/`

5. Serve judge backbone

- ☐ Chạy trên server, repo root:

```
HF_TOKEN=<read-token> bash scripts/ec2/serve_vllm.sh # Llama-3.1-8B @ :8001
```

- ☐ Kiểm tra health: `curl http://127.0.0.1:8001/health`
- ☐ Lần đầu sẽ tải thêm embedding model all-MiniLM-L6-v2 (~90 MB) — cần internet
- ☐ (RQ4) Serve thêm backbone khác mỗi cái một port (xem mục 8)

6. Validate end-to-end giá rẻ (bắt buộc trước full run)

- ☐ `bash scripts/ec2/run\_real.sh smoke` — dummy judge, 40 payloads, chỉ kiểm tra plumbing (KHÔNG dùng số liệu này)
- ☐ Sửa `configs/ec2\_real\_evaluation.yaml`: `limit: 200, n\_seeds: 1, measure\_epsilon: false`
- ☐ `bash scripts/ec2/run\_real.sh full` — chạy thử rẻ hơn để xác nhận pipe, cache, outputs
- ☐ Kiểm tra outputs xuất hiện: `outputs/real/real\_evaluation\_summary.csv, provenance.json`

7. Full run (Table 5/6)

- ☐ Sửa lại config: `limit: 0` (toàn bộ payload), `n\_seeds: 3, measure\_epsilon: true, calibrate: true`
 - Đảm bảo cache verdict rỗng với run sẽ báo cáo (đo cost/thời gian trên cold cache)
- ☐ `bash scripts/ec2/run\_real.sh full` (ước tính ~8400 judge calls $\approx$ 4–5 h serial trên GPU mid)
- ☐ `bash scripts/ec2/run\_real.sh ablate` — Table 6 (reuse honest cache, thêm ít chi phí)
- ☐ Chạy thêm benchmark nếu cần: `advbench, injecagent, dan, formal, second\_order` (đổi `data.benchmark`, dùng chung cache)

8. RQ4 — diverse committee (sau khi có Table 5/6)

- ☐ Chọn cách: (a) nâng lên g5.12xlarge hoặc (b) dùng model nhỏ hơn trên cùng GPU
- ☐ Serve mỗi backbone một port (lưu ý: `serve\_vllm.sh` tự thoát nếu đã có vLLM đang chạy → start tay hoặc sửa script)
- ☐ Map trong config:

```
judges:
  backbones: [llama-3, qwen2.5, mistral]
  models:
    llama-3: meta-llama/Llama-3.1-8B-Instruct
    qwen2.5: Qwen/Qwen2.5-7B-Instruct
    mistral: mistralai/Mistral-7B-Instruct-v0.3
  endpoints:
    llama-3: http://127.0.0.1:8001/v1
    qwen2.5: http://127.0.0.1:8002/v1
    mistral: http://127.0.0.1:8003/v1
```

- ☐ Chạy lại `run\_real.sh full` (cache cũ của backbone khác vẫn tái dùng được)
- ☐ So sánh ρ (đo bằng `estimators.py`) và ASR-UC giữa homogeneous vs diverse

9. Ghi nhận kết quả (paper honesty — bắt buộc)

- ☐ Giữ nguyên mọi `*provenance.json` cùng các CSV output
- ☐ Cập nhật `audits/result\_integrity\_audit.md`: run nào thật, nguồn data, lệnh + hash
- ☐ Chỉ `set is\_paper\_result: true` SAU khi áp checklist verify và chạy lại độc lập (`docs/reproducibility.md`)
- ☐ Điền các ô `--` trong Table 5/6 và thay figure placeholder (`pgfplots\_placeholder\_results.tex`)

10. Dọn dẹp (tránh phí)

- ☐ Lưu outputs + provenance xuống máy Windows (`scp/git`)
- ☐ **Stop** instance khi không dùng (vẫn tính phí disk nhỏ), hoặc **Terminate** nếu xong hẳn
- ☐ Thu hồi key pair / xóa security group không dùng

11. Ước tính chi phí tham khảo

- `g5.xlarge` $\approx$ \$1.0/h; `g5.12xlarge` $\approx$ \$4.5/h (giá có thể thay đổi theo region — kiểm tra trên AWS Pricing)
- Full run: $\sim 4\text{--}5$ h trên `g5.xlarge` $\rightarrow$ budget $\sim 5\text{--}10$ USD cho 1 benchmark
- Spot instance có thể giảm $\sim 60\text{--}90\%$ phí (rủi ro bị interrupt — dùng cho validate, không dùng cho run cuối)